



**Tecnológico
de Monterrey**

Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Querétaro

TC3007C Inteligencia artificial avanzada para la ciencia de datos II

Módulo 2 Análisis y Reporte sobre el desempeño del modelo.

Profesores:

Benjamín Valdés Aguirre

Carlos Alberto Dorantes Dosamantes

José Antonio Cantoral Ceballos

Ismael Solis Moreno

Eduardo Daniel Juárez Pineda

Presenta:

José Emiliano Riosmena Castañón – A01704245

Fecha:

Jueves, 21 de noviembre del 2024

Índice

Introducción.....	3
Descripción del Dataset.....	4
Uso de ETL (Extract – Transform – Load)	6
Implementación de Red Neuronal.....	8
Construcción del modelo CNN	8
Entrenamiento del modelo	10
Análisis de Resultados	12
Resultados R^2	12
Pérdida.....	13
Desempeño en Testing	13
Predicciones del modelo	15
Implementación de mejoras	17
Análisis de resultados (Implementación mejorada).....	18
Resultados R^2	18
Pérdida.....	19
Desempeño en Testing	19
Predicciones del modelo (Implementación mejorada).....	21
Comparación de resultados	22
Conclusiones Generales	24
Referencias	25

Introducción

En este ensayo, hablaremos sobre el proceso seguido para construir un modelo CNN para identificar si un acorde es mayor o menor. Por eso, en este análisis se presentará una discusión sobre el conjunto de datos utilizado, el uso de las técnicas y algoritmos vistos en clase para el desarrollo del modelo, y los desafíos presentados durante la implementación de este último.

Por último, veremos los resultados del desempeño de nuestro modelo, analizando su nivel de precisión, su capacidad de identificar la tónica en diferentes acordes en el conjunto de prueba, y en datos ajenos al dataset. De este modo nos permitirá concluir si el modelo es efectivo para cumplir su objetivo.



Descripción del Dataset

Para entender cómo funcionara el modelo, vamos a definir lo que es un acorde, y entender lo que significa un acorde mayor o menor. En una guitarra, un acorde es un conjunto de tres o más notas que se tocan al mismo tiempo. Esto genera uno de los principales componentes de la música, la armonía. En la guitarra, esto se produce apretando ciertas cuerdas en ciertos trastes, y tocando varias cuerdas al mismo tiempo, y produce un sonido más completo que una sola nota. En la música, los acordes se clasifican según su calidad, esta describe las notas específicas que lo componen y cómo se relacionan entre sí. Cada calidad transmite una sensación distintiva, lo que permite expresar diferentes emociones o “colores” musicales.

En el caso específico de este proyecto, estamos identificando únicamente mayores y menores. La diferencia entre un acorde mayor y un acorde menor está en la tercera nota que lo compone, conocida como la tercera del acorde.

- **Acorde Mayor:** Tiene una tercera mayor, es decir, 4 semitonos arriba de la raíz. Su sonido se percibe como alegre, brillante o abierto. Y se escriben de la misma forma que su raíz. Por ejemplo, el acorde de Do mayor se escribiría como Do, o en su notación en inglés como C.
- **Acorde Menor:** Tiene una tercera menor, es decir, 3 semitonos arriba de la raíz. Su sonido se percibe como melancólico, triste u oscuro. Se escriben añadiendo la letra “m” minúscula al lado de la raíz. Por ejemplo, el acorde de Do menor se escribiría como Dom, o en su notación en inglés como Cm.




Figura 1.0. Ejemplo de acorde mayor. Mi o E.




Figura 1.1. Ejemplo de acorde menor. Mim o Em.

Entendiendo esto, vamos a ver los datos que hemos utilizado para este modelo. El dataset es un conjunto de archivos de audio, los cuales contienen una mezcla de diferentes acordes reproducidos ya sea en guitarra acústica o eléctrica. Los archivos vienen clasificados en dos subcarpetas: mayor y menor, las cuales representan a los acordes mayores y menores.




Figura 1.2. Muestra del dataset utilizado.

Como hemos mencionado al principio de este documento, el objetivo de este proyecto es generar un modelo que sea capaz de identificar si un acorde dado es mayor o menor.

Uso de ETL (Extract – Transform – Load)

Para la extracción de los datos, en este dataset particular, los dos datos venían en un formato decente para su utilización. Pues, los archivos de audio ya vienen clasificados en su diferente tónica. Por lo que solo es necesario almacenarlos en nuestras variables X y Y, siendo X para cada uno de los archivos de audio, y Y su predicción si es mayor o menor.

```
def load_dataset(data_dir):  
    """  
    This function loads the dataset from the specified directory.  
    The dataset is expected to have two subdirectories: 'major' and 'minor'.  
    Each subdirectory should contain audio files corresponding to major and  
    minor chords, respectively.  
  
    Parameters:  
    - data_dir (str): path to the dataset directory  
    - Returns: X (np.ndarray), y (np.ndarray), filenames (list)  
    """  
    X, y, filenames = [], [], []  
    for label in ['major', 'minor']:  
        folder = os.path.join(data_dir, label)  
        for filename in os.listdir(folder):  
            if filename.endswith('.wav'):  
                audio_path = os.path.join(folder, filename)  
                spectrogram = audio_to_spectrogram(audio_path)  
                X.append(spectrogram)  
                y.append(0 if label == 'major' else 1)  
                filenames.append(filename)  
  
    return np.array(X), np.array(y), filenames
```

Figura 2.0. Función para cargar el dataset en arreglos para X y Y.

Pero antes de continuar, es importante que aclaremos algo muy importante. Al principio del modelo mencionamos que trabajaríamos en un CNN, pero esta última esta diseñada para analizar datos en forma de imágenes. Y nuestro conjunto de datos son archivos de audio. Entonces podríamos preguntarnos ¿cómo vamos a hacer un CNN si nuestros datos no están en formato de imágenes? Para ello debemos transformar el audio en una representación visual, un espectrograma. Un espectrograma es una imagen que muestra cómo cambian las frecuencias de audio en el tiempo. Y podemos utilizar un CNN para analizar estos espectrogramas ya como imágenes, y extraer patrones y características relevantes para la clasificación o el reconocimiento.

En la Figura 2.0 podemos observar la llamada a una función “audio_to_spectrogram” que, cómo su nombre sugiere, convierte los archivos de audio en espectrogramas, permitiendo al modelo trabajar sobre estas imágenes.

Esta función recibe cuatro parámetros:

1. audio_path: La ruta al archivo del audio a procesar.
2. n_fft: El tamaño de la ventana del FFT (Fast Fourier Transform), esta define el nivel de detalle frecuencial del espectrograma.
3. hop_length: El número de muestras entre ventanas sucesivas en la FFT, determina el solapamiento entre frames.
4. fixed_size: El tamaño deseado del espectrograma en alto y ancho.

Utilizamos la librería de librosa para cargar el archivo de audio, calcular el espectrograma en escala de mel, el cual es un tipo de espectrograma adaptado a cómo el oído humano percibe el sonido, y convertir la escala de potencia a decibelios para hacerla más interpretable. Por último, simplemente redimensionamos el espectrograma al tamaño fijo establecido en la función.

```
def audio_to_spectrogram(audio_path, n_fft=2048, hop_length=512, fixed_size=(128, 128)):
    """
    This function reads an audio file and computes its mel spectrogram.
    The mel spectrogram is then converted to decibels and resized to a fixed size.

    Parameters:
    - audio_path (str): path to the audio file
    - n_fft (int): length of the FFT window
    - hop_length (int): number of samples between successive frames
    - fixed_size (tuple): desired size of the spectrogram
    - Returns: resized mel spectrogram (np.ndarray)
    """
    # Load the audio file and compute its mel spectrogram
    y, sr = librosa.load(audio_path, sr=None)
    spectrogram = librosa.feature.melspectrogram(y=y, sr=sr, n_fft=n_fft, hop_length=hop_length)
    log_spectrogram = librosa.power_to_db(spectrogram, ref=np.max)

    # Resize the spectrogram to the fixed size
    if log_spectrogram.shape[1] < fixed_size[1]:
        pad_width = fixed_size[1] - log_spectrogram.shape[1]
        log_spectrogram = np.pad(log_spectrogram, ((0, 0), (0, pad_width)), mode='constant')

    return log_spectrogram[:fixed_size[0], :fixed_size[1]]
```

Figura 2.1. Función para convertir un audio a espectrograma.

En la función original para cargar el dataset, se manda a llamar esta función para cada archivo, las convertimos a espectrogramas, y las almacenamos en nuestro arreglo de X. Para el arreglo Y, guardamos la etiqueta de cada archivo, es decir, si es mayor o menor. Y con eso, ya tenemos nuestro dataset cargado y listo, por lo que ya podemos construir nuestro modelo.

Implementación de Red Neuronal

Llegamos a la implementación de nuestro modelo, cómo hemos mencionado en los puntos anteriores, vamos a trabajar con un CNN. Anteriormente mencionábamos el proceso de convertir los archivos de audio a espectrogramas para poder así trabajar con imágenes que nuestro CNN pueda procesar.

Construcción del modelo CNN

El modelo esta construido de la siguiente forma:

```
# Build the CNN model
model = Sequential([
    Conv2D(32, (3, 3), activation='relu', input_shape=(128, 128, 1)),
    BatchNormalization(),
    MaxPooling2D((2, 2)),
    Dropout(0.3),

    Conv2D(64, (3, 3), activation='relu'),
    BatchNormalization(),
    MaxPooling2D((2, 2)),
    Dropout(0.3),

    Conv2D(128, (3, 3), activation='relu'),
    BatchNormalization(),
    MaxPooling2D((2, 2)),
    Dropout(0.4),

    Flatten(),
    Dense(128, activation='relu'),
    BatchNormalization(),
    Dropout(0.5),

    Dense(2, activation='softmax')
])
```

Figura 3.0. Estructura del modelo CNN

El modelo utiliza tres bloques convolucionales para extraer las características de nuestras imágenes, luego conecta estas características a capas densas que realizan la clasificación final. Echemos un vistazo a cada capa:

1. La primera capa convolucional es de 32 filtros, cada uno con tamaño de 3x3. Utilizamos relu como función de activación, introduce no linealidad, y nos permite que la red pueda aprender patrones complejos. Y por último definimos que las imágenes de entrada son de tamaño 128x128 y en escala de grises.

- a. **Batch Normalization:** Normaliza la salida de la capa anterior, estabilizando y acelerando el entrenamiento.
 - b. **Max Pooling:** Reducimos la resolución de las características de entrada a la mitad, eso nos ayuda a reducir el tamaño de la imagen y captura características más generales.
 - c. **Dropout:** Desconectamos al azar el 30% de las neuronas durante el entrenamiento para evitar overfitting y mejorar la capacidad de generalización.
2. En la segunda capa, utilizamos 64 filtros de tamaño 3x3. Esto nos permite extraer características más complejas y detalladas de las imágenes de entrada, como bordes y texturas de mayor nivel. Volvemos a utilizar relu como función de activación para ayudar a la red a aprender representaciones más complejas.
- a. **Batch Normalization:** Volvemos a utilizar esta función para normalizar las salidas de la capa para que tengan una media cercana a 0 y una desviación estándar cercana a uno, de este modo, podemos estabilizar y acelerar el entrenamiento.
 - b. **Max Pooling:** Al igual que la capa anterior, volvemos a utilizar esta función para reducir las dimensiones de las características a la mitad, de ese modo podemos conservar la información más relevante, y reducimos el número de parámetros, mejorando la eficiencia de la red.
 - c. **Dropout:** Del mismo modo, desactivamos el 30% de las neuronas de esta capa durante cada iteración del entrenamiento. Como mencionábamos, esto nos ayudará a prevenir el overfitting al forzar que la red aprenda patrones robustos sin depender de neuronas específicas.
3. En la tercera capa utilizamos 128 filtros con tamaño de 3x3. De este modo, la red profundiza aún más en la extracción de características, logrando capturar patrones aún más complejos que en las capas anteriores. Al igual que las capas anteriores, utilizamos relu para mantener la no linealidad en las representaciones.

- a. **Batch Normalization:** Volvemos a utilizar esta función para normalizar la salida de la capa, de ese modo aseguramos que los valores estén bien distribuidos y facilitando la optimización y la estabilidad.
 - b. **Max Pooling:** Nuevamente, nos ayuda a reducir a la mitad, la resolución de las características, extrayendo patrones más generales, y resumiendo la información clave.
 - c. **Dropout:** En esta ocasión, estamos desactivando un 40% de las neuronas en el entrenamiento. Estamos usando este valor ya que la red está en etapas donde tiene características de alto nivel, por lo tanto, queremos asegurarnos de prevenir el overfitting.
4. En nuestra capa final, estamos usando Flatten para convertir la salida 2D en un vector 1D, permitiéndonos conectar con la capa densa.
- a. **Dense:** La capa densa esta completamente conectada con 128 neuronas. En este punto se realiza la clasificación en función de las características aprendidas.
 - b. **Batch Normalization:** Como hemos mencionado anteriormente, utilizamos esta función para normalizar la salida para asegurar que los valores estén distribuidos de forma correcta y mejorar la optimización y estabilidad del modelo.
 - c. **Dropout:** En este caso desconectamos el 50% de las neuronas para reducir el riesgo de un overfitting.
 - d. **Dense (2):** La capa de salida tiene 2 neuronas, una para cada clase (mayor o menor). Utilizamos softmax para convertir los valores en probabilidades, permitiendo obtener la clase final.

Entrenamiento del modelo

Además del modelo definido anteriormente. Hemos implementado algunas optimizaciones para ayudar al modelo a tener un mejor rendimiento y estabilidad, y evitar el overfitting.

1. **Optimizador:** Estamos utilizando AdamW, le asignamos un learning rate inicial de $1e-5$. Además, estamos definiendo un weight decay de 0.001 para la regularización.

```
# Create an optimizer
optimizer = AdamW(learning_rate=0.001, weight_decay=1e-5)
```

Figura 3.1. Optimizador AdamW para el modelo.

2. **Checkpoint para el mejor modelo:** Este nos permite guardar el resultado de los modelos en cada epoch, en cada uno de los pasos del entrenamiento, el callback analiza la precisión en validation en el epoch actual, y si el resultado es mejor que el epoch anterior, entonces el modelo se guarda y nos permitirá utilizar ese modelo guardado para las predicciones.

```
# Create a callback to save the best model during training
checkpoint_callback = ModelCheckpoint(
    'models/temp_best_model.keras',
    monitor='val_accuracy',
    mode='max',
    save_best_only=True,
    verbose=1
)
```

Figura 3.2. Callback para guardar el mejor modelo durante el entrenamiento.

3. **Callback para reducir el learning rate:** Utilizamos una instancia de ReduceLROnPlateau, como su nombre sugiere, reducimos el learning rate durante el entrenamiento cuando el modelo deja de mejorar, lo que puede ayudar a salir de mínimos locales y mejorar el rendimiento en general.

```
# Create a callback to reduce the learning rate when the validation loss plateaus
lr_reduction = ReduceLROnPlateau(monitor='val_loss', patience=3, factor=0.5, min_lr=1e-6)
```

Figura 3.3. Callback para reducir el learning rate.

Una vez que hemos definido nuestras optimizaciones, el siguiente paso es entrenar el modelo, analizar los resultados y tratar de realizar predicciones con nuestro modelo. En nuestro caso, veremos si nuestro modelo es capaz de identificar si un acorde es mayor o menor.

Análisis de Resultados

Para el entrenamiento del modelo hemos utilizado un total de 50 epochs, y un batch_size de 32, el cual establece el tamaño de la cantidad de muestras que se procesan antes de actualizar los parámetros del modelo. Con ese tamaño definido, el modelo ajustará los pesos cada vez que haya procesado 32 muestras.

Echemos un vistazo a los resultados.

Resultados R^2

```
Epoch 43/50 -- 0s 156ms/step - accuracy: 0.9768 - loss: 0.0418  
13/13  
Epoch 43: val_accuracy improved from 0.92000 to 0.94000, saving model to models/temp_best_model.keras  
13/13 -- 2s 179ms/step - accuracy: 0.9767 - loss: 0.0425 - val_accuracy: 0.9400 - val_loss: 0.1773 - learning_rate: 6.2500e-05
```

Figura 4.0. Epoch del mejor modelo adquirido durante el entrenamiento

1. **Train R^2 → 97.67%:** La precisión en training nos dice que el modelo clasifica correctamente si un acorde es mayor o menor en aproximadamente 97.67% de los casos.
2. **Validation R^2 → 94%:** La precisión en validation nos dice que tenemos un buen indicador de cómo el modelo podría funcionar con datos nuevos, en este caso, nos dice que el modelo podría ser efectivo para acordes nuevos e identificar si su tónica es mayor o menor.

La diferencia entre ambas precisiones es pequeña. Esto es un resultado positivo, ya que una diferencia más alta nos indicaría que el modelo tiene overfitting. Y en nuestro modelo, la diferencia es pequeña como para sugerir que el modelo está generalizando bien, sin memorizar en exceso los datos de entrenamiento.




Figura 4.1. Visualización de la precisión en Training y Validation

Pérdida

1. **Training** → **0.0425**: Esta pérdida es una medida de cuán bien el modelo se ajusta a los datos, en este caso la pérdida es muy baja, lo que nos indica que tenemos un buen ajuste en el modelo.
2. **Validation** → **0.1773**: Este valor es más alto que la pérdida en training, lo cual es normal. En los modelos bien ajustados, se espera que la pérdida de validación sea un poco más alta que la de entrenamiento, ya que el modelo está expuesto a datos que no ha visto antes.

La diferencia entre training y validation sugiere que el modelo está funcionando bien, aunque esta diferencia nos dice que el modelo tiene un pequeño margen para mejorar su capacidad de generalización. Pero en general, nos indica que el problema de overfitting es mínimo.

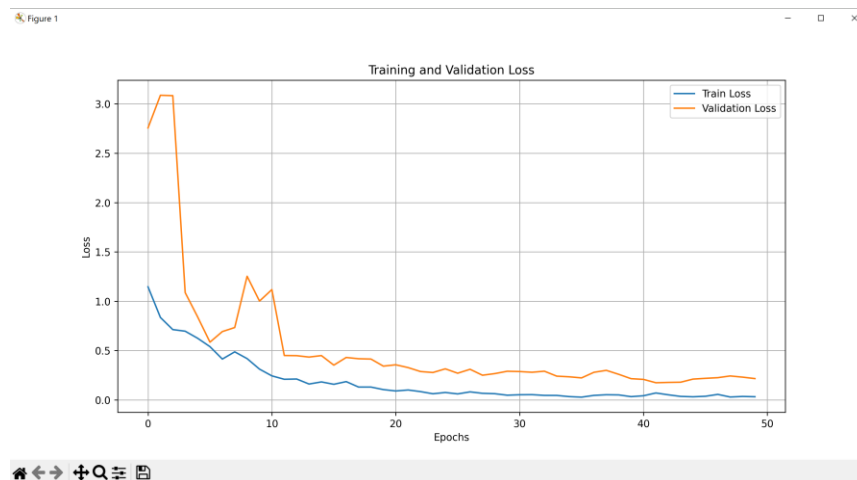


Figura 4.2. Visualización de la pérdida en Training y Validation

Desempeño en Testing

```
2/2 ————— 0s 22ms/step - accuracy: 0.9269 - loss: 0.3465
2/2 ————— 0s 102ms/step
Test Accuracy: 92.16%
```

Figura 4.3. Desempeño del modelo en Testing

Adicional al análisis del desempeño en Training y Validation, hemos separado parte del dataset en Testing para probar y realizar predicciones rápidas. Al evaluar nuestro modelo, obtuvimos una precisión del 92.16%, con una pérdida de 0.3465. Lo que nos permite decir que el modelo en general tiene un buen desempeño, la

pérdida es un poco mayor a la pérdida en Validation, sin embargo, la diferencia es muy pequeña, por lo que nos permite decir que el modelo aún tiene buen ajuste, y es lo suficientemente apto para determinar la tónica mayor o menor de un acorde.

```
Predictions:
Chord: 3_2.wav - Prediction: minor
Chord: 4_5.wav - Prediction: major
Chord: 7_52.wav - Prediction: minor
Chord: 4_19.wav - Prediction: major
Chord: 5_25.wav - Prediction: major
Chord: 5_12.wav - Prediction: major
Chord: 9_74.wav - Prediction: major
Chord: 3_7.wav - Prediction: major
Chord: 1_7.wav - Prediction: major
Chord: 1_26.wav - Prediction: minor
```

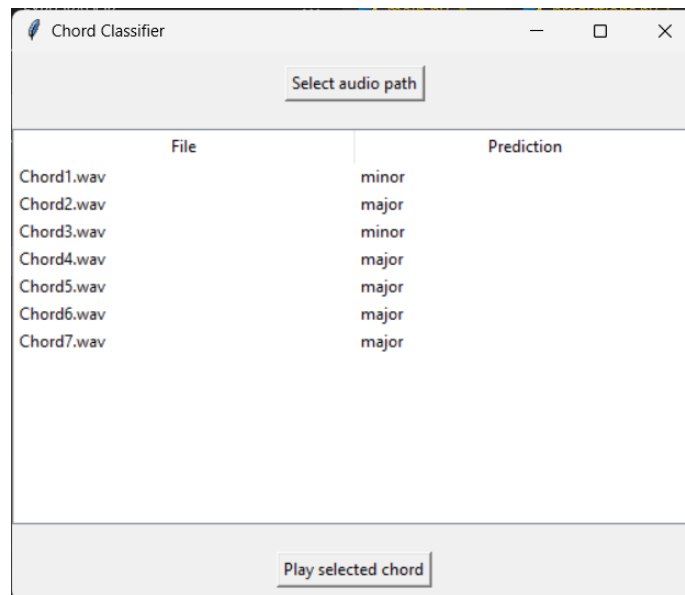
Figura 4.4. Ejemplo de predicciones en Testing

Adicional al modelo, hemos implementado que pueda realizar predicciones en el conjunto de Testing del dataset original, en general podemos ver que tiene un buen desempeño y en la mayoría de los acordes presentados en la Figura 4.4 ha obtenido un resultado correcto. Sin embargo, hay que aclarar algo importante, en el dataset, tanto en la subcarpeta mayor como en menor, hay casos donde el archivo se llama exactamente igual que en el subconjunto de la tónica contraria, por lo que algunos de estos resultados se mantienen ambiguos, pues no sabemos a cuál de estos archivos está realizando la predicción.

Para poder determinar la predicción sin ambigüedad y determinar si se equivoca o no, vamos a realizar las predicciones por aparte. En la siguiente sección veremos a detalle cómo hemos realizado el código para las predicciones, y veremos los resultados finales.

Predicciones del modelo

En la sección anterior vimos la capacidad del modelo para realizar predicciones en el conjunto de Testing, sin embargo, pudimos notar que los resultados de esas predicciones son ambiguos y no nos permiten llegar a un resultado completo. Para eso, hemos implementado un código por aparte para poder determinar con mayor exactitud las predicciones del modelo. Para ello hemos construido una interfaz, en la que estamos utilizando un pequeño conjunto con datos ajenos al dataset original. En la interfaz se nos permite la opción de escuchar el acorde, y adicionalmente incluye la predicción, de ese modo, nos permite a nosotros como humanos escuchar el acorde y por cuenta propia determinar si es mayor o menor, y comparar con el resultado de la predicción del modelo.



The screenshot shows a window titled "Chord Classifier" with a "Select audio path" button at the top. Below is a table with two columns: "File" and "Prediction". The table lists seven audio files and their corresponding predicted chord types. At the bottom of the window is a "Play selected chord" button.

File	Prediction
Chord1.wav	minor
Chord2.wav	major
Chord3.wav	minor
Chord4.wav	major
Chord5.wav	major
Chord6.wav	major
Chord7.wav	major

Figura 5.0. Visualización gráfica de las predicciones

En este ejemplo podemos ver a mejor detalle las predicciones del modelo, cómo mencionábamos anteriormente, podemos escuchar el acorde que queramos y a simple oído podemos determinar si es mayor o menor y compararlo con la predicción del modelo.

Después de realizar esta comparación podemos determinar con mayor detalle que el modelo aún tiene áreas de mejora en la que podría mejorar su desempeño, pues algunas de estas predicciones son incorrectas. Esto puede ser por algunas razones

diferentes, puede ser que cómo mencionábamos anteriormente, el modelo aún tiene un poco de margen de mejora, y podríamos intentar mejorar su desempeño para obtener resultados más precisos, o puede ser que cómo los acordes utilizados para este nuevo conjunto de prueba, al ser diferentes que los del conjunto original, realiza predicciones diferentes debido a cómo se ve su espectrograma, por lo que quizás sea necesario entrenar el modelo con más datos, en este caso más ejemplos de acordes.

Implementación de mejoras

Hemos visto el desempeño del modelo y hemos visto que ha dado buenos resultados con un ligero margen de error. Por lo que hemos realizado unas pocas mejoras para tratar de obtener un mejor desempeño aún. Para ello, hemos implementado un programador del learning rate, utilizando el método ExponentialDecay de TensorFlow.

```
# Define a learning rate schedule
lr_schedule = tf.keras.optimizers.schedules.ExponentialDecay(
    initial_learning_rate=0.001,
    decay_steps=10000,
    decay_rate=0.9
)
```

Figura 6.0 Función para el learning rate

Este método ajusta automáticamente la tasa de aprendizaje durante el entrenamiento del modelo. Definimos como learning rate inicial, un valor de 0.001, y le estamos asignando cómo cantidad de batches procesados, el valor de 10000. Esto significa que, después de 10000 pasos, la tasa de aprendizaje se reducirá. Y por último el factor por el que se multiplica la tasa de aprendizaje en cada etapa del ajuste. Esto quiere decir que el learning rate se reducirá al 90% de su valor actual en cada intervalo de 10000 pasos.

Este método se manda a llamar en el optimizador AdamW, estableciéndolo como parámetro de learning rate del optimizador y eliminamos los pesos de este último.

```
# Create an optimizer
optimizer = AdamW(learning_rate=lr_schedule)
```

Figura 6.1. Optimizador AdamW actualizado con los nuevos parámetros

Dado a que ya habíamos obtenido un buen desempeño con el modelo original, las mejoras que hemos implementado son mínimas, pero considero que le permitirán al modelo obtener un mejor desempeño e identificar correctamente la tónica mayor o menor de los acordes.

Con estas mejoras, vamos a conocer los nuevos resultados del modelo.

Análisis de resultados (Implementación mejorada)

Para el entrenamiento del modelo, hemos incrementado la cantidad de épocas en 10, dándonos un total de 60 epochs de entrenamiento, el resto de los parámetros para el entrenamiento se ha mantenido de forma igual.

Echemos un vistazo a los nuevos resultados.

Resultados R²

```
Epoch 40/60  
13/13 ----- 0s 158ms/step - accuracy: 0.9871 - loss: 0.0357  
Epoch 40: val_accuracy improved from 0.92000 to 0.96000, saving model to models/temp_best_model.keras  
13/13 ----- 2s 175ms/step - accuracy: 0.9870 - loss: 0.0361 - val_accuracy: 0.9600 - val_loss: 0.2187
```

Figura 7.0. Resultados de R² en training y validation del nuevo modelo

En esta implementación, hemos obtenido una precisión mayor que en el modelo pasado, pasando de 94% a 96% lo cual es una mejora en el rendimiento del modelo, ya que nos está diciendo que el modelo está generalizando bien a datos nuevos, indicando que su capacidad para decir si un acorde es mayor o menor, en el 96% de los casos resulta ser cierto.

También, en el modelo anterior, la precisión en Training nos había dado de 97%, y en este nuevo modelo la precisión en Training ha subido a 98%, por lo tanto, estos resultados indican que hemos logrado reducir el overfitting en el modelo, por ende, logrando un mejor desempeño.

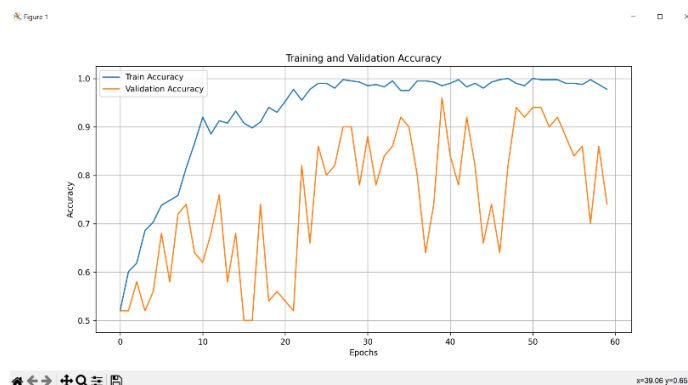


Figura 7.1 Desempeño de la precisión durante el entrenamiento

Por otro lado, la gráfica de la precisión de este modelo es muy diferente con respecto a la gráfica anterior. Mientras que la curva de aprendizaje en Training muestra una mejora constante, la curva en Validation muestra una alta variabilidad, con

fluctuaciones significativas entre épocas, indicando un problema de overfitting, por lo que el modelo podría no estar generalizando bien a los datos de validación.

Afortunadamente, en la implementación pasada, habíamos construido un callback para salvar el mejor modelo durante el entrenamiento, de ese modo, estamos conservando el modelo en el que la precisión Validation alcanzo su punto más alto (96%).

Pérdida

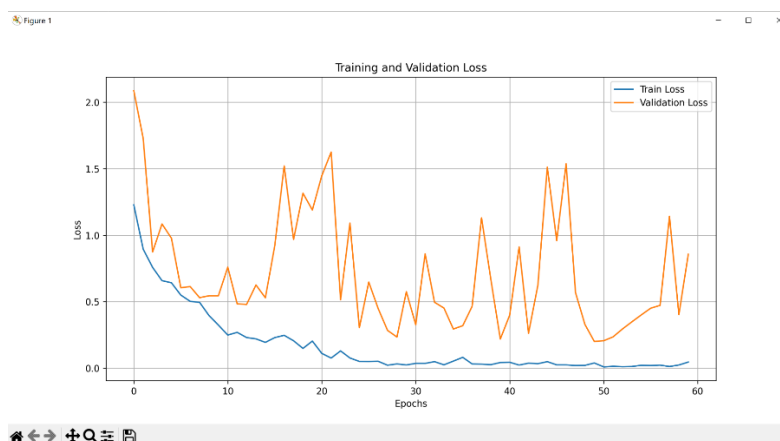


Figura 7.2 Pérdida del modelo durante el entrenamiento.

Similar al punto anterior, la gráfica muestra un comportamiento diferente en comparación al modelo anterior. Mientras que la curva de pérdida en Training disminuye de forma constante a lo largo de las épocas. La curva de Validation muestra una pérdida muy errática, y en promedio, no disminuye de forma significativa a medida que avanzan en las épocas. Lo que nos dice que el modelo no está generalizando bien a los datos de validación. Sugiriendo que el modelo presenta overfitting, pues no puede generalizar bien a datos nuevos. Indicando que el modelo podría no ser lo suficientemente eficiente para identificar correctamente la tónica mayor o menor de los acordes.

Desempeño en Testing

```
Evaluating the model on the test set...
2/2 ██████████ 0s 21ms/step - accuracy: 0.9138 - loss: 0.2570
2/2 ██████████ 0s 86ms/step
Test Accuracy: 90.20%
```

Figura 7.3. Desempeño del modelo en Testing

En este caso el desempeño para el conjunto de prueba es bastante efectivo. Sin embargo, muestra una disminución en comparación con el modelo anterior bajando de 92% a 90%, significando que nuestro modelo no fue capaz de identificar de mejor manera los acordes mayores y menores de los archivos de audio del conjunto de Testing. Pero, aun así, la disminución es baja por lo que el modelo sigue teniendo un buen desempeño y aún puede ser efectivo para identificar los acordes mayores o menores.

```
Predictions:
Chord: 3_2.wav - Prediction: minor
Chord: 4_5.wav - Prediction: major
Chord: 7_52.wav - Prediction: minor
Chord: 4_19.wav - Prediction: major
Chord: 5_25.wav - Prediction: major
Chord: 5_12.wav - Prediction: minor
Chord: 9_74.wav - Prediction: major
Chord: 3_7.wav - Prediction: major
Chord: 1_7.wav - Prediction: major
Chord: 1_26.wav - Prediction: minor
```

Figura 7.4 Predicciones del modelo en el conjunto de Testing

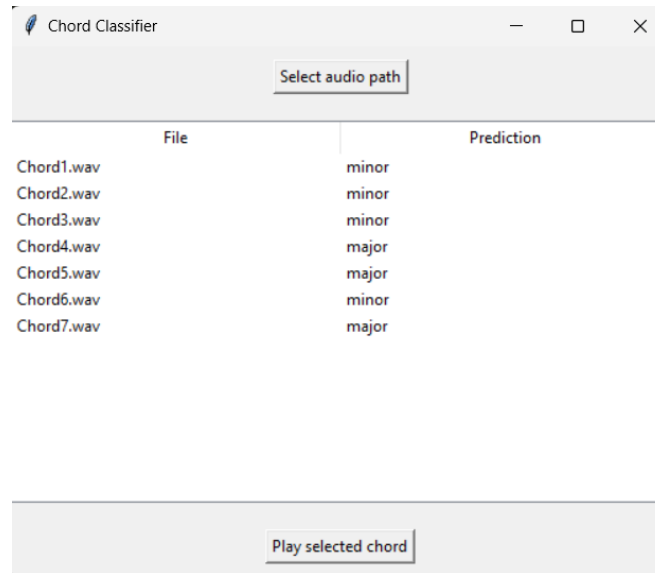
En este caso tenemos un cambio con los acordes del conjunto de entrenamiento, en general tiene un buen desempeño y ha logrado identificar la tónica del acorde de forma correcta en la mayoría de los casos.

Anteriormente mencionábamos que existía el caso de que el nombre del acorde se podría llamar de la misma forma en la carpeta de mayor o menor, y en este caso es igual, no es posible conocer cual de estos dos acordes es el que está tomando para identificar. Sin embargo, a la hora de probar el código, un error, nos indico que tuvo un problema para leer el archivo específico para la predicción, y ese error decía la ruta a la que estaba tratando de acceder, por lo tanto, tenemos algunas pocas referencias de qué subcarpeta esta tomando el acorde para interpretar.

Al igual que el modelo anterior vamos a evaluar los resultados de las predicciones en acordes nuevos, permitiendo la posibilidad de escucharlos e identificar la tónica mayor o menor y comparar con la predicción del modelo.

Predicciones del modelo (Implementación mejorada)

Como decíamos en la implementación, las predicciones realizadas directamente en el conjunto de Testing, aún son ambiguas para determinar si los identifica correctamente. Por ello, vamos a volver a utilizar nuestra interfaz para mostrar los acordes utilizados, escucharlos y nosotros a puro oído identificar la tónica mayor o menor del acorde, y con ello poder compararlo con la predicción del modelo.



The screenshot shows a window titled "Chord Classifier" with a "Select audio path" button at the top. Below it is a table with two columns: "File" and "Prediction". The table lists seven audio files and their corresponding predicted chord types. At the bottom of the window is a "Play selected chord" button.

File	Prediction
Chord1.wav	minor
Chord2.wav	minor
Chord3.wav	minor
Chord4.wav	major
Chord5.wav	major
Chord6.wav	minor
Chord7.wav	major

Figura 8.0. Predicciones del nuevo modelo

Estos resultados muestran un buen desempeño con la identificación de acordes, en general, la mayoría de las predicciones son correctas, con algunos errores. Esto sugiere que el modelo aún tiene áreas en donde puede ser mejorado, quizás, implementando técnicas de regularización, o añadiendo más datos a los conjuntos de entrenamiento y validación, o tal vez buscar otra arquitectura que nos pudiera ayudar en mayor medida que el actual.

Sin embargo, en comparación al modelo anterior, el nuevo modelo ha tenido más errores a pesar de haber obtenido un desempeño mejor en R^2 . Por lo que es necesario realizar comparativas entre los resultados de este nuevo modelo con el anterior y analizar cual es mejor para identificar acordes mayores o menores.

Comparación de resultados

En general ambos modelos obtuvieron un muy buen desempeño, con diferencias en algunos casos muy pequeñas y en otros, más grandes. En esta sección vamos a comparar estos resultados y llegaremos a una conclusión sobre cual de los dos modelos tiene un mejor desempeño.

Criterios	Implementación 1	Implementación 2
R² Training	97.67%	98.70%
R² Validation	94%	96%
R² Testing	92.16%	90.20%
Pérdida Training	0.0425	0.0361
Pérdida Validation	0.1773	0.2107
Pérdida Testing	0.3465	0.2570
Predicciones Testing	10/10	9/10
Predicciones Music_Chords	5/7	4/7

Gráficas

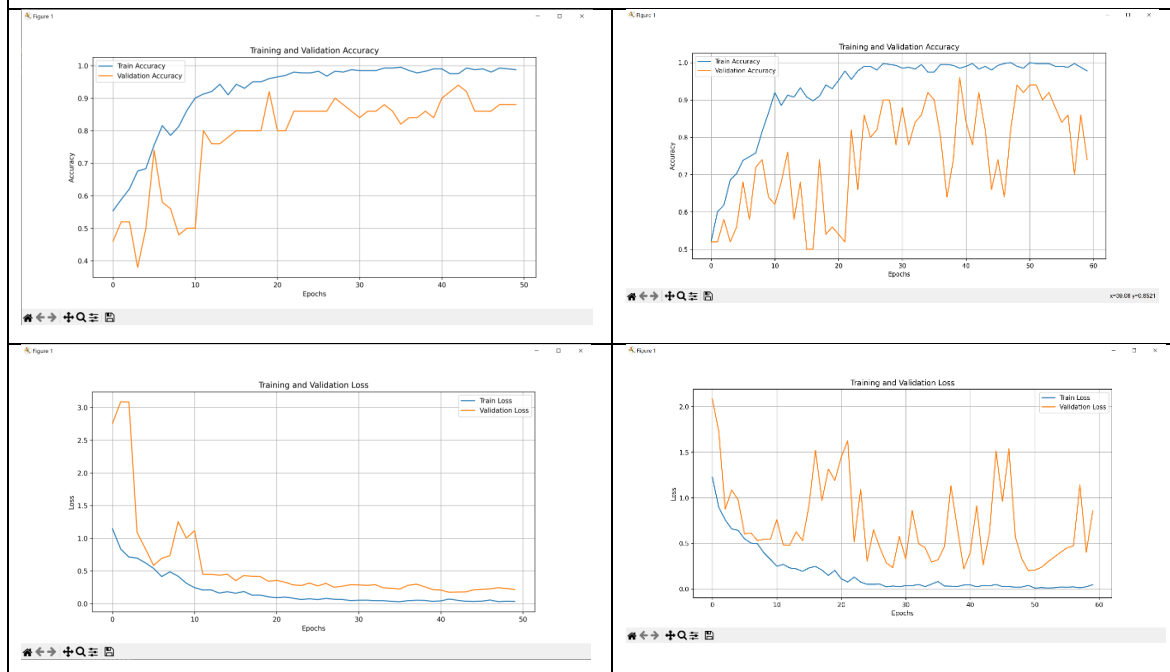


Tabla 1.0 Comparación de resultados entre el primer y segundo modelo.

Estos son los resultados de ambos modelos, en lo que es esta comparativa podemos ver que es bastante reñida, ambos modelos tienen puntos a favor

similares. Mientras que el primero modelo obtuvo mejores resultados en las predicciones, el segundo modelo obtuvo mejores resultados en el entrenamiento. De los 8 criterios establecidos en la Tabla 1.0 4 son a favor del modelo 1 y 4 son a favor del modelo 2. Lo que nos indica que la diferencia de estos modelos es muy baja, sugiriendo que ambos modelos son efectivos.

Sin embargo, al analizar las gráficas, podemos decir que el primer modelo tiene un mejor desempeño, pues muestra un crecimiento constante en la precisión y un decremento constante en la pérdida, mientras que el segundo modelo muestra alta variabilidad tanto en la precisión como en la pérdida. Aunque implementamos un callback para salvar el mejor modelo en los entrenamientos, los resultados de las gráficas indican que el segundo modelo presenta un mayor problema de overfitting que el primer modelo.

Además, el objetivo principal de este proyecto era lograr que el modelo pudiera identificar si un acorde es mayor o menor, y las predicciones del primer modelo son mejores que el segundo modelo. Por lo tanto, podemos concluir que el primer modelo es mejor que el segundo modelo, ya que realiza mejores predicciones y presenta un mejor ajuste.

Conclusiones Generales

Recapitulando lo que hemos hablado en este reporte, hemos visto un poco sobre teoría de los acordes y cómo nosotros como personas podemos identificar la tónica mayor o menor de un acorde. Hemos visto las técnicas y herramientas utilizadas en la construcción de los modelos. Visualizamos los resultados de los modelos en Training, Validation y Testing. Y hemos visto sus capacidades para predecir la tónica mayor o menor de un acorde.

Comparamos ambos modelos y pudimos concluir que el primer modelo fue más efectivo que el segundo, ya que, si bien, ambos lograron identificar correctamente la mayoría de las tónicas de los acordes, el primer modelo logro resultados casi perfectos, con muy pocos errores. Y en general, presenta un comportamiento continuo durante su entrenamiento, y no muestra un problema de overfitting tan inmenso como el segundo modelo.

Ambos modelos tienen buen desempeño, pero aún podemos analizar más áreas de oportunidad en ambos y en un futuro mejorar aun más sus desempeños. Pero, en general podemos decir que el objetivo del proyecto se ha cumplido, pues sí hemos podido generar un modelo que identifique correctamente un acorde mayor o menor. Y nos permitiría en un futuro mejorarlo o adaptarlo a múltiples funcionalidades, cómo reconocimiento de acordes en vivo, o ampliarlo para identificar más formas en las que se pueden presentar los acordes.

Referencias

Анатолий Михайлин (2021). *Major VS Minor guitar chords*. Kaggle.

<https://www.kaggle.com/datasets/mehanat96/major-vs-minor-guitar-chords>

Vinci F. (2021). *GUITAR CHORDS V3*. Kaggle.

<https://www.kaggle.com/datasets/fabianavinci/guitar-chords-v3>

Hugging Face (s.f.). *Introducción a los datos de audio*.

https://huggingface.co/learn/audio-course/es/chapter1/audio_data

IBM (s.f.). *¿Qué son las redes neuronales convolucionales?*

<https://www.ibm.com/mx-es/topics/convolutional-neural-networks>